ChronoLens: Decoding Customer Behaviors via Neural Representation and ML-Driven Web Frameworks

Trần Nam Hải, Nguyễn Vũ Trung Kiên, Phạm Tiến Dũng
Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội, Việt Nam
Email: {trannamhai.5d, ngkienn89, tiendungcbh1801}@gmail.com

Đội thi HD4K - Vòng bán kết cuộc thi DataFlow 2026

***Tóm tắt nội dung*—Trong bối cảnh quản trị chuỗi cung ứng hiện đại, dự báo chính xác tiến độ giao dịch và nhu cầu công suất nhà máy từ chuỗi hành vi khách hàng là bài toán then chốt nhằm tối ưu hóa rủi ro tồn kho. Tuy nhiên, việc hồi quy đồng thời đa tham số từ các chuỗi tương tác có độ dài biến thiên đặt ra thách thức lớn về hội tụ lệch pha và dịch chuyển phân phối. Bài báo cáo đề xuất ChronoLens - một framework lai hai giai đoạn nhằm giải quyết bài toán hồi quy đa mục tiêu. Đóng góp cốt lõi của hệ thống bao gồm: (1) Hệ sinh thái Chrono Networks tích hợp cơ chế *Cascade Regression* giúp mô hình hóa quy luật nhân quả thời gian; (2) Hàm mất mát *Asymmetric Hybrid-Threshold Loss* tích hợp hệ số phạt rủi ro nghiệp vụ, tối ưu hóa trực tiếp thước đo Weighted MSE (WMSE); và (3) Chiến lược chưng cất đặc trưng sang XGBoost kết hợp huấn luyện toàn cục, giúp triệt tiêu sai số dư và đạt tốc độ suy luận tiệm cận không. Thực nghiệm chứng minh sự vượt trội của ChronoLens khi đạt Val WMSE 0.1917 và Public Test WMSE 0.1930, xuất sắc giành vị trí Top 2 trên bảng xếp hạng Kaggle. Hệ thống cũng cung cấp khả năng giải thích minh bạch thông qua mạng lưới nhân quả đồ thị, sẵn sàng triển khai thực tế trên quy mô doanh nghiệp. Mã nguồn khả dụng tại: https://github.com/CryAndRRich/chronolens.**

***Từ khoá*—Hồi quy đa mục tiêu, Chuỗi hành vi biến thiên, Chưng cất đặc trưng, Asymmetric Loss, Weighted MSE, Explainable AI.**

I. GIỚI THIỆU BÀI TOÁN

Trong bối cảnh quản trị chuỗi cung ứng hiện đại, việc tối ưu hóa lịch trình sản xuất và phân bổ công suất nhà máy là thách thức sống còn đối với các doanh nghiệp quy mô lớn. Quản lý điều phối bị động dễ dẫn đến rủi ro quá tải cục bộ, lãng phí tài nguyên hoặc đứt gãy tiến độ giao hàng. Do đó, việc dự báo sớm tiến độ giao dịch và nhu cầu công suất dựa trên chuỗi hành vi khách hàng là bài toán cấp thiết, giúp đội ngũ vận hành chủ động thiết lập kịch bản sản xuất và tối ưu hóa diện tích lưu kho.

Bước vào vòng chung kết cuộc thi "*DataFlow 2026: The Alchemy of Minds*", thử thách ban tổ chức đưa ra là giải quyết bài toán hồi quy đa mục tiêu. Cụ thể, hệ thống phải dự báo đồng thời 6 tham số vận hành liên tục (bao gồm thời gian và chỉ số hoạt động) từ dữ liệu tương tác của khách hàng trong quá khứ.

Kế thừa triết lý từ vòng bán kết, đội thi HD4K đề xuất **ChronoLens** - một framework xoay quanh ba trụ cột cốt lõi:

- **Chưng cất đặc trưng sâu:** Xây dựng hệ sinh thái **Chrono Networks** gồm 3 kiến trúc học sâu chuyên biệt gồm **Chrono-C** (Convolutional) trích xuất đặc trưng cục bộ, **Chrono-R** (Recurrent) học phụ thuộc dài hạn, và **Chrono-G** (Graph) lập bản đồ tương tác phi tuyến. Thay vì dự đoán trực tiếp, các mạng nơ-ron này đóng vai trò bộ trích xuất biểu diễn, nén chuỗi hành vi hỗn độn thành các vector nhúng dày đặc.
- **Hệ thống học máy dự báo:** Tận dụng không gian ngữ cảnh chất lượng cao làm đầu vào để huấn luyện các mô hình cây quyết định (như XGBoost, LightGBM). Các kiến trúc cây quyết định sở hữu độ trễ suy luận cực thấp và tốn ít tài nguyên bộ nhớ, đảm bảo hệ thống có khả năng mở rộng và phản hồi mượt mà trong thời gian thực khi triển khai xử lý luồng dữ liệu khổng lồ ở môi trường vận hành thực tế.
- **Định hướng giải quyết nghiệp vụ:** Đóng gói toàn bộ luồng suy luận thành nền tảng Web tương tác. Chuyển hóa 6 thông số dự báo thành các chỉ thị điều hành tự động, hỗ trợ doanh nghiệp lên lịch trình sản xuất, giám sát rủi ro quá tải nhà máy và tối ưu hóa không gian kho bãi theo thời gian thực.

Bảng I: Bảng xếp hạng Kaggle Contest

Rank	Team	Public Test Score (↓)
1	HiddenLayer	0.11023
2	**HD4K**	**0.19303**
3	UET.epoch_0	0.21571
4	Sailor Moon	0.21762
5	The invicibles	0.23464

II. PHÂN TÍCH DỮ LIỆU

A. *Tổng quan về bộ dữ liệu*

Bộ dữ liệu tại vòng chung kết sử dụng các giao dịch thực tế đã qua xử lý ẩn danh, ghi nhận chuỗi hành vi của khách hàng trong tập huấn luyện. Cấu trúc dữ liệu được thiết kế nhằm mô phỏng lộ trình tương tác của người dùng và các hệ quả vận hành tương ứng:

- **Dữ liệu đầu vào:** Chuỗi các hành động của người dùng đã được mã hóa thành số nguyên nhằm bảo mật thông tin. Đặc trưng cốt lõi của dữ liệu là tính biến thiên về độ dài chuỗi do tần suất và số lượng tương tác của mỗi người dùng không đồng nhất. Thực nghiệm trên tập Train cho thấy chiều dài chuỗi dao động từ 3 đến 66 hành động, phân phối lệch phải rõ rệt với đa số tập trung ở mốc 10-20 bước.

- **Dữ liệu đầu ra:** Bao gồm 6 biến mục tiêu liên tục, tương ứng với 6 thuộc tính hành vi cần dự báo. Các thuộc tính `attr_1`, `attr_2`, `attr_4`, `attr_5` đại diện cho tháng và ngày bắt đầu cũng như hoàn thành giao dịch. Trong đó, `attr_3` và `attr_6` phản ánh chỉ số hoạt động (công suất) của nhà máy. Toàn bộ dữ liệu đầu ra yêu cầu định dạng số nguyên không dấu 16-bit (`UINT16`).

B. Phân tích đặc trưng và Insight nghiệp vụ

Hệ thống ChronoLens được xây dựng không chỉ dựa trên tối ưu toán học, mà còn bắt nguồn từ việc giải mã "ngôn ngữ hành vi" thành các điểm nghẽn chuỗi cung ứng. Quá trình khai phá dữ liệu (EDA) đã bóc tách 3 phát hiện cốt lõi sau **(Chi tiết các bằng chứng định lượng và biểu đồ thống kê được trình bày tại Phụ lục A và Phụ lục B)**:

1) Động lực học chuỗi và Ngưỡng khám phá: Thông qua thống kê tần suất, vị trí xuất hiện và khai phá các chuỗi N-grams (Bigram/Trigram), chúng tôi nhận diện rõ 3 giai đoạn tâm lý của khách hàng:

- **Điểm chạm khởi đầu:** Các mã `760`, `685` chiếm tỷ trọng áp đảo tại vị trí đầu chuỗi, đại diện cho các nguồn truy cập khác nhau (mở trực tiếp ứng dụng hoặc qua liên kết quảng cáo).
- **Ngưỡng khám phá:** Chuỗi hành vi phổ biến nhất thường hội tụ về mã `8615` (ví dụ: 685 $\rightarrow$ 2207 $\rightarrow$ 8615). Trước mã này, người dùng chỉ ở trạng thái tải trang. Ngay sau `8615`, luồng hành vi bắt đầu phân nhánh mạnh mẽ, biến đây thành "thời điểm vàng" để hệ thống đề xuất can thiệp.
- **Nút thắt điều hướng:** Các mã `105`, `102` xuất hiện với tần suất khổng lồ nhưng hiếm khi ở đầu hoặc cuối chuỗi, đóng vai trò là các trạm trung chuyển (Trang chủ, Giỏ hàng) nối liền các thao tác xem chi tiết.

2) Tính mùa vụ và Quán tính giao dịch: Đối với 4 thuộc tính thời gian (`attr_1`, `attr_2`, `attr_4`, `attr_5`), phân tích ma trận Cramer's V và phân phối độ lệch chỉ ra sự tương quan cực kỳ chặt chẽ giữa mốc bắt đầu và hoàn thành (độ lệch chủ yếu tập trung tại giá trị 0). Khách hàng có quán tính kết thúc giao dịch rất nhanh sau khi khởi tạo.

Đặc biệt, đồ thị biến động công suất theo trục thời gian (Ngày trong tháng - `attr_2`) phát hiện một **Vùng dồn đơn** nằm ở giai đoạn cuối tháng (từ ngày 25 đến 31). Đây là thời điểm công suất trung bình của toàn nhà máy tăng vọt, đòi hỏi sự chuẩn bị chủ động về nguồn lực.

3) Phân tích rủi ro vận hành: Ngược lại với nhóm thời gian, 2 thuộc tính công suất (`attr_3` và `attr_6`) có hệ số tương quan rất thấp, chứng tỏ chúng đại diện cho 2 khâu vận hành hoàn toàn độc lập.

Để trả lời câu hỏi *"Hành vi nào có nguy cơ gây quá tải hệ thống cao nhất?"*, chúng tôi thiết kế hệ số nâng **Lift Score**, đo lường tỷ lệ xuất hiện của một mã hành động trong nhóm giao dịch gây quá tải (công suất $>$ 90th percentile) so với nhóm bình thường. Kết quả đã khoanh vùng được 11 mã hành động vĩ mô. Đây là các tín hiệu báo động đỏ, đại diện cho các hành vi như: khách hàng B2B gom hàng sỉ, yêu cầu cấu hình tùy chỉnh phức tạp, hoặc hủy hay đổi lệnh sản xuất phút chót. Việc bóc tách thành công các mã này là tiền đề để ChronoLens kích hoạt hệ thống cảnh báo sớm trên giao diện Web App.

III. XỬ LÝ DỮ LIỆU

Để đảm bảo chất lượng đầu vào cho các mạng nơ-ron sâu và ngăn chặn hiện tượng học vẹt, quy trình tiền xử lý và tăng cường dữ liệu được thiết kế cực kỳ nghiêm ngặt. Phân tích thăm dò (EDA) đã chỉ ra các điểm bất thường về logic thời gian và sự dịch chuyển phân phối, đòi hỏi các kỹ thuật can thiệp chuyên sâu.

A. Làm sạch và xử lý dữ liệu

Tính toàn vẹn của tập kiểm định và tính hợp lý của dữ liệu đích là yếu tố tiên quyết để mô hình hồi quy hoạt động chính xác. Chúng tôi tiến hành xử lý ba vấn đề cốt lõi:

- **Khắc phục rò rỉ và trùng lặp dữ liệu:** Hệ thống đã loại bỏ hoàn toàn các chuỗi hành vi trùng lặp nội bộ, bao gồm 99 mẫu trong tập Train và 110 mẫu trong tập Val. Quan trọng hơn, thuật toán tự động dò tìm và triệt tiêu 187 chuỗi bị rò rỉ (chồng chéo) từ tập Train sang tập Validation, đảm bảo môi trường kiểm định hoàn toàn độc lập và khách quan.
- **Chuẩn hóa vi phạm logic thời gian:** Vì bài toán yêu cầu dự báo chính xác ngày và tháng, một số nhãn trong dữ liệu gốc vi phạm quy tắc lịch pháp (ví dụ: ngày 31 tháng 4). Quá trình quét đã phát hiện 1010 mẫu lỗi ngày tháng trong tập Train và 749 mẫu trong tập Val. Thuật toán sử dụng ma trận quy chiếu để tự động giới hạn (*clip*) các ngày bị lỗi này về mốc tối đa hợp lệ của tháng tương ứng.
- **Trích xuất đặc trưng giao năm:** Phát hiện trường hợp tháng kết thúc (`attr_4`) nhỏ hơn tháng bắt đầu (`attr_1`), hệ thống tự động bổ sung thêm đặc trưng `end_year = 1` (thể hiện giao dịch kéo dài qua năm mới).

B. Khắc phục dịch chuyển phân phối bằng nội suy động

Sự chênh lệch nghiêm trọng về phân bố độ dài chuỗi giữa dữ liệu huấn luyện và tập kiểm thử **(Phụ lục C)** gây rủi ro suy giảm hiệu suất cực lớn trên môi trường thực tế.

Thay vì nhân bản dữ liệu một cách tuyến tính [1], hệ thống ChronoLens áp dụng chiến lược nội suy động (*dynamic oversampling*) [2]. Thuật toán liên tục đối chiếu tần suất của từng mức độ dài, nếu một nhóm độ dài bị thiểu số trong tập Train nhưng lại xuất hiện nhiều ở tập Test, hệ thống sẽ tự động tính toán một hệ số nhân linh hoạt (giới hạn tối đa 10 lần) để nhân bản nhóm dữ liệu đó. Kỹ thuật này đã giúp tập Train tăng mạnh từ 54.714 mẫu lên 105.245 mẫu, ép mạng nơ-ron phải trích xuất đặc trưng cẩn thận hơn đối với các phiên giao dịch thưa thớt, thiết lập sự cân bằng về phân phối.

C. Mã hóa và tăng cường nhiễu ngẫu nhiên

Toàn bộ danh mục hành động được ánh xạ qua một từ điển thống nhất (*Vocabulary*) với kích thước 934 nhãn, trong đó mã hóa `PAD=0` cho khoảng trắng và `UNK=1` cho các mã dị biệt. Sau đó, chúng tôi triển khai hai kỹ thuật tăng cường ngẫu nhiên nhằm gia tăng tính bền vững:

- **Giãn nở chuỗi ngẫu nhiên:** Với xác suất 50%, hệ thống phân tán ngẫu nhiên các hành động thực tế trên toàn bộ không gian của chuỗi, giữ nguyên thứ tự tuần tự nhưng chèn thêm mã `PAD` vào giữa. Cơ chế nhiễu an toàn này giúp mô hình học được tính bất biến về không gian (*spatial invariance*) [3], buộc mạng nơ-ron phải

thấu hiểu logic nhân quả thay vì chỉ học thuộc khoảng cách liền kề.

- **Che lấp ngẫu nhiên:** Lấy cảm hứng từ cơ chế *Masked Language Modeling* [4], với xác suất 50%, chúng tôi che lấp 10% lượng hành động trong chuỗi thành mã 0. Phương pháp này đóng vai trò như một cơ chế điều chuẩn mạnh mẽ [5], ngăn chặn mạng nơ-ron quá khớp vào một vài "từ khóa" hành động nhất định, ép hệ thống suy luận dựa trên bối cảnh toàn cục của chuỗi.

IV. PHƯƠNG PHÁP ĐỀ XUẤT

A. *Quy trình huấn luyện 2 giai đoạn*

Để đáp ứng yêu cầu khắt khe về tốc độ phản hồi thời gian thực khi triển khai hệ thống Web App ở quy mô doanh nghiệp, **như được minh họa tại Hình 1**, chúng tôi từ bỏ phương pháp suy luận *end-to-end* nặng nề của mạng học sâu. Thay vào đó, ChronoLens sử dụng quy trình huấn luyện 2 giai đoạn, lấy việc tối ưu hóa độ trễ làm kim chỉ nam:

- **Giai đoạn 1 (*Feature Extractor*):** Các kiến trúc mạng học sâu thuộc hệ sinh thái Chrono Networks được huấn luyện trên chuỗi hành động biến thiên. Tại đây, mạng nơ-ron không đóng vai trò ra quyết định cuối cùng mà hoạt động như một bộ trích xuất đặc trưng (*feature extractor*) siêu việt. Chúng nén các chuỗi hành vi thô, nhiễu loạn thành các không gian vector ngữ cảnh đặc (*deep embeddings*), chứa đựng toàn bộ quy luật nhân quả của dòng thời gian.
- **Giai đoạn 2 (*Machine Learning Ensemble*):** Đây là bước đột phá về mặt hiệu năng. Các mô hình Học sâu (đặc biệt là Graph và Recurrent) vốn sở hữu "nút thắt cổ chai" về tài nguyên tính toán, gây cản trở tốc độ suy luận. Để giải quyết, chúng tôi đóng băng (*freeze*) toàn bộ trọng số mạng nơ-ron, chỉ trích xuất các *embeddings* làm đầu vào để huấn luyện các mô hình cây quyết định siêu nhẹ, giúp hệ thống đạt được **tốc độ suy luận tính bằng mili-giây** (*ultra-low latency*). Khối lượng tính toán được giảm tải tối đa, cho phép nền tảng Web dễ dàng gánh vác các tính năng tính toán cường độ cao mà không xảy ra hiện tượng giật lag.
- **Chiến lược huấn luyện toàn cục (*Full-fit Retraining*):** Nhằm tối đa hóa hiệu năng dự báo trên bảng xếp hạng thực tế, tập kiểm định (Validation set) ban đầu được sử dụng độc lập để thiết lập cơ chế dừng sớm (*early stopping*) và dò tìm các siêu tham số (*hyperparameters*) tối ưu nhất cho hệ thống. Sau khi chốt được số lượng epoch hội tụ và cấu hình tham số chuẩn, chúng tôi tiến hành hợp nhất tập Train và Val thành một kho dữ liệu duy nhất. Các mô hình (cả Deep Learning và Machine Learning) sau đó được huấn luyện lại từ đầu (*retrain*) trên khối lượng dữ liệu khổng lồ này. Phương pháp này giúp mô hình hấp thụ trọn vẹn các biến thiên quý giá của dữ liệu trước khi đưa ra dự đoán cuối cùng trên tập Test.

B. *Hàm mất mát tùy chỉnh*

Thước đo đánh giá tại vòng chung kết là Weighted L2 (MSE) với các hệ số phạt $\alpha = 100$ được áp đặt cực kỳ khắt khe lên các thuộc tính công suất. Việc tối ưu hóa trực tiếp bằng hàm MSE thông thường sẽ đối mặt với rủi ro bùng nổ đạo hàm ở giai đoạn đầu do các sai số ngoại lai, đồng thời dễ khiến mạng nơ-ron bị hội tụ lệch pha giữa các mục tiêu.

Để giải quyết triệt để điểm nghẽn này, chúng tôi thiết kế hàm mất mát **Asymmetric Hybrid-Threshold Loss** mang bản chất của *Adaptive Huber Loss* [6], tích hợp cơ chế trọng số [7], ngưỡng nội suy tuyến tính theo thời gian và hệ số phạt bất đối xứng định hướng nghiệp vụ [8].

Đầu tiên, sai số tuyệt đối chuẩn hóa của từng thuộc tính

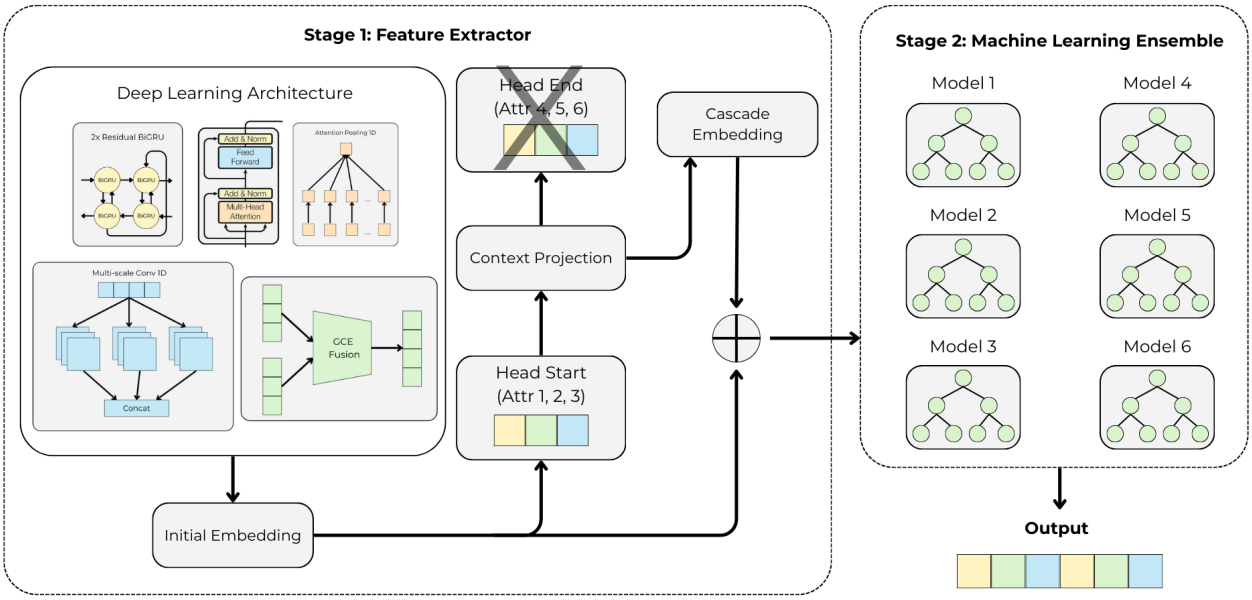

Hình 1: Quy trình huấn luyện 2 giai đoạn của hệ thống ChronoLens

j trên mẫu i được định nghĩa là:

$$E_{i,j} = \frac{|\hat{y}_{i,j} - y_{i,j}|}{M_j}$$

Trong đó, M_j là hằng số chuẩn hóa không gian nhãn tương ứng của thuộc tính j. Hàm suy hao lõi được tính toán bằng cách kết hợp mượt mà giữa L1 và L2 dựa trên một ngưỡng δ:

$$\mathcal{L}_{Huber}(E_{i,j}, \delta) = \begin{cases} \frac{1}{2}E_{i,j}^2 & \text{nếu } E_{i,j} \leq \delta \\ \delta \cdot E_{i,j} - \frac{1}{2}\delta^2 & \text{nếu } E_{i,j} > \delta \end{cases}$$

Để định hướng hành vi của mô hình theo đúng rủi ro thực tế, chúng tôi áp dụng hệ số phạt bất đối xứng $\gamma_{i,j}$:

$$\gamma_{i,j} = \begin{cases} 1.5 & \text{nếu } j \in \text{Thời gian và } \hat{y}_{i,j} > y_{i,j} \text{ (Dự báo muộn)} \\ 1.5 & \text{nếu } j \in \text{Công suất và } \hat{y}_{i,j} < y_{i,j} \text{ (Dự báo thiếu)} \\ 1.0 & \text{các trường hợp còn lại} \end{cases}$$

Tổng suy hao của toàn mạng (*total loss*) tại một thời điểm huấn luyện (epoch t) được tổng hợp thông qua vector trọng số đa nhiệm $w^{(t)}$ kết hợp với hệ số phạt $\gamma_{i,j}$:

$$\mathcal{L}_{total}^{(t)} = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{6} w_j^{(t)} \cdot \gamma_{i,j} \cdot \mathcal{L}_{Huber}\left(E_{i,j}, \delta^{(t)}\right)$$

Tính đột phá của hàm mất mát này nằm ở việc kết hợp logic vận hành nhà máy và cơ chế điều hướng động (*dynamic annealing*) thông qua tỷ lệ tiến độ $progress = t/T$ (với T là tổng số epochs):

- **Phạt bất đối xứng nghiệp vụ ($\gamma_{i,j}$):** Lấy cảm hứng từ triết lý chuỗi cung ứng "thừa công suất còn hơn thiếu hụt, hoàn thành sớm còn hơn trễ hẹn". Nếu mô hình dự báo ngày hoàn thành muộn hơn thực tế gây trễ dây chuyền, hoặc dự báo công suất thấp hơn thực tế dẫn đến quá tải nhà máy, sai số lập tức bị nhân hệ số phạt gấp rưỡi ($1.5\times$). Cơ chế này ép mạng nơ-ron học cách thiên vị (*bias*) các dự đoán an toàn, giảm thiểu rủi ro đứt gãy vận hành.
- **Ngưỡng chuyển đổi động ($\delta^{(t)}$):** Thay vì cố định, δ được mở rộng tuyến tính từ 0.01 lên 0.05. Ở các epoch đầu, δ nhỏ khiến hàm hoạt động chủ yếu như MAE (L1), giúp mô hình kháng nhiễu tốt và tránh bùng nổ đạo hàm. Ở giai đoạn cuối, δ lớn dần, mở rộng vùng tiệm cận bậc hai (MSE/L2) để dồn lực tinh chỉnh các sai số vi mô, bám sát thước đo của cuộc thi.
- **Học theo giáo trình đa nhiệm ($w^{(t)}$):** Trọng số của các đầu ra không cố định mà dịch chuyển từ một cấu hình khởi tạo (w_{start}) sang cấu hình đích (w_{end}). Chiến lược này cho phép mạng nơ-ron ưu tiên hội tụ các thuộc tính nền tảng trước, sau đó mới tập trung tài nguyên để giải quyết các thuộc tính có độ khó cao (như công suất nhà máy), tránh hiện tượng các nhiễu cục bộ phá vỡ không gian biểu diễn chung của mô hình.

C. Nhóm mô hình Chrono Networks

Cốt lõi trích xuất đặc trưng của ChronoLens là hệ sinh thái các mô hình học sâu chuyên trách xử lý dữ liệu chuỗi biến thiên, mang tên Chrono Networks. Thay vì dùng *Global Average Pooling* truyền thống dễ gây loãng thông tin, tất cả các mô hình trong hệ sinh thái đều được trang bị lớp *AttentionPooling1D*. Lớp này tính toán trọng số tầm quan trọng (*attention scores*) cho từng mốc thời gian, đồng thời triệt tiêu nhiễu từ các vị trí đệm (*padding*) bằng kỹ thuật *Masked Fill* với giá trị âm vô cùng ($-\infty$). Kết quả đầu ra là một vector biểu diễn (*Deep Embedding*) cực kỳ tinh gọn và giàu ngữ cảnh.

Hệ sinh thái khai thác không gian giả thuyết đa dạng thông qua ba kiến trúc cốt lõi:

- **Chrono-G (Graph Network):** Tiếp cận chuỗi hành vi dưới lăng kính cấu trúc đồ thị (*graph topology*) [9]. Mô hình hóa mỗi hành động như một đỉnh và mối liên hệ thời gian như cạnh (hướng về quá khứ và tương lai), Chrono-G xuất sắc trong việc lập bản đồ các tương tác phi tuyến và cung cấp khả năng giải thích (*xAI*) mạnh mẽ.
- **Chrono-R (Recurrent Network):** Khai thác cơ chế bộ nhớ ngắn hạn có cổng (như GRU [10] / LSTM [11]), kiến trúc này duy trì tính tuần tự nhân quả nghiêm ngặt của dòng sự kiện theo trục thời gian tuyến tính.
- **Chrono-C (Convolutional Network):** Ứng dụng các khối tích chập tách biệt chiều sâu (*depthwise separable convolution*) [12], Chrono-C có thế mạnh vượt trội trong việc dò tìm các mẫu hành vi cục bộ với chi phí tính toán cực thấp.

Điểm đột phá trong kiến trúc của Chrono Networks không chỉ nằm ở khối trích xuất mà ở tư duy thiết kế luồng suy luận. Thông thường, các mô hình học máy dự báo song song cả 6 đầu ra cùng lúc. Tuy nhiên, thực tế vận hành chỉ ra một quy luật nhân quả bất biến: giai đoạn hoàn thành giao dịch bắt buộc phải phụ thuộc vào giai đoạn khởi tạo.

Để mô hình hóa quy luật này, chúng tôi thiết kế cơ chế **Cascade Regression** (Hồi quy phân tầng) [13] thay thế cho các lớp *classifier heads* thông thường. Quy trình dự báo được chia làm 2 bước nối tiếp:

1) **Dự báo Khởi tạo:** Vector nhúng được đưa qua khối hồi quy bậc 1 để dự báo 3 thuộc tính của giai đoạn bắt đầu, bao gồm tháng ($\hat{y}_1$), ngày ($\hat{y}_2$) và chỉ số hoạt động nhà máy ($\hat{y}_3$).
2) **Dự báo hoàn thành có điều kiện:** Thay vì dự báo độc lập, bộ 3 giá trị dự báo ở bước 1 ($\hat{y}_1, \hat{y}_2, \hat{y}_3$) được nối ngược trở lại với vector nhúng ban đầu. Khối thông tin tổng hợp này tiếp tục được truyền qua khối hồi quy bậc 2 để dự báo 3 thuộc tính của giai đoạn kết thúc ($\hat{y}_4, \hat{y}_5, \hat{y}_6$).

Cơ chế *Cascade* này hoạt động như một hệ thống neo bối cảnh (*contextual anchor*), ép mạng nơ-ron phải nhận thức được thời điểm và khối lượng bắt đầu trước khi quyết định thời điểm kết thúc. Mạng lưới nhờ đó tự động triệt tiêu các lỗi logic ngớ ngẩn (như ngày kết thúc diễn ra trước ngày bắt đầu), đồng thời tối ưu hóa đáng kể thước đo Weighted MSE.

V. KẾT QUẢ THỰC NGHIỆM

A. Thiết lập thực nghiệm

Thực nghiệm được tiến hành trên máy chủ Kaggle (NVIDIA Tesla T4 GPU) với tham số `RANDOM_SEED` $= 42$.

Dữ liệu đầu vào được giới hạn ở độ dài chuỗi tối đa `SEQ_LENGTH` $= 66$. Không gian biểu diễn đặc trưng được thiết lập với số chiều `EMBEDDING_DIM` $= 256$.

Mạng nơ-ron được huấn luyện với `BATCH_SIZE` = 1024 trong tối đa `NUM_EPOCHS` = 100. Cơ chế dừng sớm (*early stopping*) được thiết lập với ngưỡng 15 epochs. Mô hình được tối ưu bằng **AdamW** [14] với *learning rate* tối đa là 10^{-3} và *weight decay* bằng 10^{-2}. Lịch trình **OneCycleLR** [15] được áp dụng với `pct_start` = 0.2 và `final_div_factor` = 10000.0.

Các tham số động của hàm mất mát được cập nhật nội suy tuyến tính theo tiến trình huấn luyện (*epoch progress*):

- **Hằng số chuẩn hóa (M):** Áp dụng vector chuẩn hóa $M = [1, 12, 31, 99, 1, 12, 31, 99]$ cho 8 mục tiêu.
- **Ngưỡng bản lề (δ):** Nội suy tuyến tính ngưỡng từ $\delta_{start} = 0.01$ đến $\delta_{end} = 0.05$.
- **Trọng số đa nhiệm (w):**

$$w_{start} = [100.0, 100.0, 100.0, 1.0, 100.0, 100.0, 100.0, 1.0]$$
$$w_{end} = [0.0, 1.0, 1.0, 100.0, 0.0, 1.0, 1.0, 100.0]$$

B. Các mô hình cơ sở

Để làm nổi bật tính ưu việt và mức độ hiệu quả của kiến trúc ChronoLens, chúng tôi tiến hành đối chiếu hiệu năng với hai nhóm mô hình cơ sở:

- **Mô hình học máy truyền thống:** Bao gồm Random Forest [16], XGBoost [17], và LightGBM [18]. Dữ liệu chuỗi đầu vào được làm phẳng thông qua kỹ thuật *mean pooling* trên không gian nhúng Word2Vec [19]. Nhóm mô hình này đóng vai trò mỏ neo để đánh giá giới hạn của các phương pháp không có khả năng nắm bắt trực tiếp sự phụ thuộc tuần tự thời gian.
- **Mạng nơ-ron hồi quy cơ bản:** Bao gồm các kiến trúc chuỗi tiêu chuẩn như Vanilla RNN, LSTM, và GRU. Các mô hình này được thiết lập tương đồng với cấu hình của *Chrono-R* nhằm đảm bảo tính công bằng tuyệt đối (*fair comparison*) trong quá trình đánh giá.

C. Các chỉ số đánh giá

Thước đo xếp hạng chính thức do ban tổ chức quy định là **Weighted MSE (WMSE)**. Đồng thời, để phục vụ quá trình phân tích toàn diện (*holistic evaluation*), chúng tôi tính toán thêm các chỉ số MAE, MSE, RMSE và WMAPE độc lập trên từng thuộc tính riêng biệt.

Giả sử y_i và $\hat{y}_i$ lần lượt là giá trị thực tế và giá trị dự báo của mẫu thứ i ($i = 1..N$) đối với một thuộc tính đơn lẻ, các chỉ số đánh giá thành phần được định nghĩa như sau:

- **Mean Absolute Error (MAE):** Đo lường trung bình độ lớn của các sai số tuyệt đối, giúp đánh giá mức độ sai lệch tổng thể mà không bị nhạy cảm quá mức với các giá trị ngoại lai.

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

- **Mean Squared Error (MSE) & Root Mean Squared Error (RMSE):** Bình phương sai số giúp phạt nặng các dự báo lệch quá xa so với thực tế, đặc biệt nhạy cảm với các lỗi dự báo rủi ro cao.

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$
$$RMSE = \sqrt{MSE}$$

- **Weighted Mean Absolute Percentage Error (WMAPE):** Đánh giá sai số tương đối theo tỷ lệ phần trăm dựa trên tổng quy mô thực tế, cực kỳ hữu ích để các kỹ sư đo lường mức độ sai lệch của các thuộc tính công suất.

$$WMAPE = \frac{\sum_{i=1}^{N}|y_i - \hat{y}_i|}{\sum_{i=1}^{N}|y_i|}$$

Đối với đánh giá tổng thể toàn hệ thống, thước đo **Weighted MSE (WMSE)** tích hợp hệ số phạt α_j cho từng thuộc tính $j \in \{1..6\}$ được áp dụng làm chỉ số quyết định (*ranking metric*):

$$WMSE = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{6}\alpha_j \cdot (y_{i,j} - \hat{y}_{i,j})^2$$

Trong đó, để định hướng bài toán sát với thực tế quản lý rủi ro nhà máy, ban tổ chức áp đặt hệ số phạt khắt khe $\alpha_j = 100$ lên các biến công suất (`attr_3`, `attr_6`), và giữ mức $\alpha_j = 1$ cho các biến thời gian còn lại. Thiết lập này đòi hỏi mô hình không chỉ dự báo chính xác mà còn phải chủ động giảm thiểu các sai số mang tính rủi ro vận hành cao.

Bảng II: Bảng so sánh hiệu năng các mô hình giai đoạn 1

Mô hình	MAE (↓)	MSE (↓)	RMSE (↓)	WMAPE (↓)	Val WMSE (↓)
Mô hình học máy truyền thống					
Random Forest	6.8385	145.5193	12.0631	29.5286	8.113
XGBoost	6.7258	137.9146	11.7437	29.0418	7.7512
LightGBM	6.6960	136.8410	11.6979	28.9133	7.6873
Mạng nơ-ron hồi quy cơ bản					
RNN	2.3632	31.2423	5.5895	10.2041	1.3398
LSTM	2.1951	29.5435	5.4354	9.4783	1.3272
GRU	2.2256	32.8008	5.7272	9.6102	1.5291
Mô hình đề xuất (Ours)					
Chrono-C	2.7539	38.2329	6.1833	11.8915	1.5685
Chrono-G	1.8624	21.7661	4.6654	8.0420	0.9599
Chrono-R	**1.5990**	**18.6676**	**4.3206**	**6.9046**	**0.8597**

So sánh toàn cục: **Hạng 1**, Hạng 2

D. Kết quả tổng thể

Dựa trên kết quả thực nghiệm của các mô hình cơ sở ở giai đoạn 1 tại Bảng II, chúng tôi rút ra ba kết luận quan trọng về đặc tính của tập dữ liệu:

- **Sự hạn chế của mô hình học máy truyền thống:** Khi huấn luyện trực tiếp trên dữ liệu chuỗi được làm phẳng, Random Forest hay LightGBM cho thấy mức sai số WMSE rất cao. Mặc dù các mô hình này xuất sắc trong việc phân chia ngưỡng đặc trưng, chúng lại hoàn toàn mù mờ trước tính tuần tự và khoảng cách nhân quả của dòng thời gian.
- **Giới hạn của mạng hồi quy cơ bản:** Các kiến trúc LSTM hay GRU thuần túy tỏ ra hụt hơi trước hệ số phạt khắt khe $\alpha = 100$. Việc thiếu vắng cơ chế chia sẻ biểu diễn đa nhiệm và phân tầng dự báo khiến các mạng này gặp hiện tượng hội tụ lệch pha, không thể tối ưu đồng thời cả mốc thời gian lẫn chỉ số công suất.
- **Sự vượt trội của kiến trúc Chrono Networks:** Cả ba kiến trúc cốt lõi (Chrono-G, Chrono-R, Chrono-C) đều thiết lập khoảng cách biệt lập so với phần còn lại. Sự thành công này là kết tinh của lớp *AttentionPooling1D, CascadeRegression* kết hợp cùng *Asymmetric Hybrid-Threshold Loss*, ép mạng nơ-ron dồn tài nguyên học hỏi để né tránh các dự báo mang rủi ro vận hành cao.

Nhằm đánh giá năng lực tối đa của hệ thống, chúng tôi tiến hành đóng băng trọng số mạng nơ-ron, trích xuất vector ngữ cảnh (*embeddings*) và huấn luyện lại hệ thống cây quyết định trên khối dữ liệu gộp Train + Val. Số liệu đối chiếu được trình bày chi tiết tại Bảng III.

Bảng III: Hiệu năng mô hình áp dụng chiến lược 2 giai đoạn

Mô hình	Val WMSE (↓)	Public Test WMSE (↓)
Chrono-G	0.9599	0.2676
Chrono-R	0.8597	0.2222
Chrono-C	1.5685	0.2693
Chrono-G + LightGBM	0.2993	0.2305
Chrono-G + XGBoost	0.2969	0.2358
Chrono-R + LightGBM	**0.1898**	0.1973
Chrono-R + XGBoost	0.1917	**0.1930**
Chrono-C + LightGBM	0.2986	0.2388
Chrono-C + XGBoost	0.3002	0.2427

Bảng III là minh chứng đắt giá nhất cho triết lý thiết kế của ChronoLens. Lấy ví dụ kiến trúc Chrono-R, khi đứng độc lập, mức sai số Val WMSE là 0.8597. Tuy nhiên, ngay khi chuyển giao không gian đặc trưng cho XGBoost, sai số lập tức sụt giảm mạnh mẽ xuống còn 0.1917.

Quan trọng hơn, để đánh giá khả năng tổng quát hóa (*generalization*), chúng tôi quan sát độ lệch giữa Val và Public Test. Sự kết hợp **Chrono-R + XGBoost** thể hiện tính ổn định đáng kinh ngạc ($0.1917 \rightarrow 0.1930$). Độ chênh lệch gần như bằng không này khẳng định chiến lược full-fit đã giúp mô hình hấp thụ hoàn toàn các biến thiên của dữ liệu, triệt tiêu triệt để hiện tượng quá khớp, đưa đội thi vươn lên vị trí Top 2 trên bảng xếp hạng thực tế.

E. Nghiên cứu cắt bỏ

Để chứng minh tính cấp thiết của quy trình huấn luyện 2 giai đoạn và các kỹ thuật can thiệp chuyên sâu, một thực nghiệm cắt bỏ đã được tiến hành trên kiến trúc cơ sở Chrono-R. Kết quả đối chiếu hiệu năng dựa trên thước đo WMSE được trình bày chi tiết tại Bảng IV.

Bảng IV: Kết quả nghiên cứu cắt bỏ các thành phần tối ưu

Mô hình	Val WMSE (↓)	Public Test WMSE (↓)
Chrono-R + XGBoost	**0.1917**	**0.1930**
Chrono-R	0.8597	0.2222
Chrono-R (*w/o year feat*)	1.0110	0.2553
Chrono-R (*w/o HybridLoss*)	0.9486	0.2646
Chrono-R (*w/o val retrain*)	0.8597	0.3199

Dựa trên dữ liệu thực nghiệm, chúng tôi rút ra 4 kết luận cốt lõi về sức mạnh của từng thành phần trong hệ thống:

- **Tác động của giai đoạn chưng cất:** Khi chỉ sử dụng mạng nơ-ron Chrono-R để dự báo trực tiếp, sai số Public Test dừng lại ở mức 0.2222. Tuy nhiên, khi áp dụng quy trình lai (trích xuất Embedding nạp vào XGBoost), sai số lập tức giảm đột phá xuống **0.1930**. Điều này minh chứng sức mạnh tuyệt đối của cây quyết định trong việc triệt tiêu sai số dư [20] mà không gian liên tục của mạng nơ-ron không thể tối ưu triệt để.
- **Tác động của đặc trưng năm (*w/o year feat*):** Việc loại bỏ biến phụ trợ `year` khiến mạng nơ-ron mất phương hướng khi tính toán khoảng cách thời gian giữa tháng 12 và tháng 1 năm sau. Hậu quả là sai số trên tập Validation và Public Test tăng vọt (1.0110 và 0.2553). Kỹ thuật đơn giản này lại đóng vai trò là chiếc "mỏ neo logic" cực kỳ quan trọng giúp mô hình không vi phạm quy tắc lịch pháp.
- **Tác động của hàm mất mát Asymmetric Hybrid-Threshold (*w/o HybridLoss*):** Khi gỡ bỏ hàm mất mát tùy chỉnh và thay bằng WMSE của ban tổ chức, mô hình mất đi cơ chế nội suy động và khả năng thiên vị rủi ro nghiệp vụ. Việc thiếu vắng lực phạt bất đối xứng khiến mạng nơ-ron dễ dàng bị nhiễu bởi các điểm dị thường, đẩy Public Test WMSE lùi về mức 0.2646.
- **Tác động của chiến lược full-fit (*w/o val retrain*):** Đây là nhân tố tạo ra sự sụp đổ nghiêm trọng nhất. Nếu chỉ huấn luyện trên tập Train và từ chối học lại trên tập Validation trước khi dự báo Test, sai số bị khuếch đại lên mức tồi tệ nhất (0.3199). Điều này khẳng định rằng, trong các bài toán hồi quy chuỗi thời gian thực tế, việc tận dụng tối đa mọi điểm dữ liệu để khắc phục sự dịch chuyển phân phối là nguyên tắc sống còn.

Thực nghiệm trên khẳng định rằng hệ sinh thái ChronoLens không phải là sự chắp vá của các thủ thuật rời rạc, mà là một cỗ máy được thiết kế chính xác đến từng chi tiết, nơi mỗi thành phần đều đóng góp trực tiếp vào sự ổn định và khả năng tối ưu hóa điểm số.

F. Khả năng giải thích của mô hình

Một trong những ưu điểm vượt trội của kiến trúc đồ thị **Chrono-G** so với các mô hình "hộp đen" (*black-box*) [21] truyền thống là khả năng giải thích được logic ra quyết định. Thông qua việc bóc tách các ma trận trọng số nội tại, chúng tôi tiến hành hai phân tích chuyên sâu nhằm chứng minh hệ thống thực sự thấu hiểu nghiệp vụ nhà máy thay vì chỉ học vẹt các mẫu thống kê.

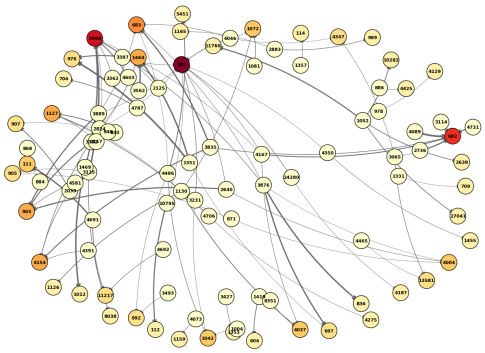

Hình 2: Mạng lưới nhân quả với 100 luồng hành vi trọng yếu được trích xuất từ trọng số của Chrono-G.

1) Đồ thị nhân quả: Bằng cách trích xuất trọng số cạnh từ cơ chế truyền tin của mạng nơ-ron đồ thị, chúng tôi tái lập mạng lưới hành vi mà mô hình học được (Hình 2).

Kết quả trực quan hóa cho thấy sự hình thành của một cấu trúc "phễu hội tụ". Hàng loạt các hành động khởi đầu khác nhau đều trỏ mũi tên với sức mạnh kết nối cực lớn (trọng số chú ý $> 80\%$) về một số đỉnh cụ thể, điển hình là mã hành động `102`. Điều này hoàn toàn khớp với phân tích nghiệp vụ ban đầu: `102` đóng vai trò là "nút thắt" điều hướng mà mọi người dùng đều phải đi qua trước khi chốt đơn. Việc Chrono-G tự động nhận diện và cấp trọng số cao cho các nút thắt này chứng minh mô hình đã nắm bắt được "topo học" của luồng khách hàng. Chi tiết hơn có thể xem tại Phụ lục D.

2) Phân tích bẫy "Ảo tưởng": Để tìm hiểu nguyên nhân tại sao hệ thống đôi khi dự báo sai lệch công suất, chúng tôi tiến hành phân tách và đối chiếu sự phân bổ trọng số chú ý giữa hai nhóm dự đoán: Sai số thấp (Đúng) và Sai số cao (Sai).

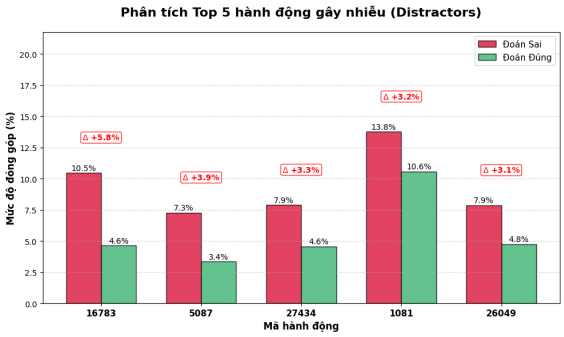

Hình 3: Biểu đồ đối chiếu mức độ tập trung Attention vào các hành động gây nhiễu giữa nhóm dự đoán Sai và Đúng trên thuộc tính 6.

Như được trình bày tại Hình 3, phân tích đã vạch trần các mã hành động đóng vai trò là "cú lừa". Lấy ví dụ mã `16783`, khi mô hình dự báo trượt hệ số công suất, nó đã dồn sự tập trung một cách bất thường vào nút này. Đây là các hành vi mang tính chất "nhiễu" (ví dụ: khách hàng lướt xem cấu hình nặng nhưng cuối cùng không đặt hàng), khiến mạng nơ-ron mất đi bối cảnh toàn cục và dẫn đến hiện tượng "ảo tưởng" (*hallucination*) [22]. Chi tiết hơn có thể xem tại Phụ lục E.

G. Khả năng mở rộng và Triển khai thực tế

Bên cạnh độ chính xác, khả năng mở rộng và triển khai thực tế (*deployment scalability*) là tiêu chí sống còn, đặc biệt khi hệ thống phải xử lý hàng triệu luồng dữ liệu khách hàng. **ChronoLens** được thiết kế với triết lý tinh gọn và tối ưu hóa tài nguyên từ tầng lõi, thể hiện qua hai khía cạnh trọng yếu:

- **Tốc độ suy luận tiệm cận không:** Các mô hình học sâu (đặc biệt là đồ thị và hồi quy chuỗi) thường sở hữu độ trễ tính toán lớn, khó đáp ứng lưu lượng truy cập khổng lồ. Để giải quyết triệt để nút thắt này, quy trình huấn luyện 2 giai đoạn của ChronoLens đã phát huy tác dụng. Bằng cách *chưng cất đặc trưng* từ Chrono Networks và giao phó trọng trách dự báo cuối cùng cho các chuyên gia học máy (như LightGBM/XGBoost), tốc độ suy luận của hệ thống được ép xuống mức mili-giây. Nền tảng Web App nhờ đó có thể hoạt động cực kỳ mượt mà, phản hồi ngay lập tức các kịch bản mô phỏng của người điều hành mà gần như không tiêu tốn tài nguyên GPU trong môi trường thực tế.
- **Khả năng mở rộng linh hoạt theo nghiệp vụ:** Điểm khác biệt mang tính chiến lược của kiến trúc Chrono-G nằm ở việc mô hình hóa chuỗi hành động dưới dạng đồ thị có hướng. Thay vì bị giới hạn bởi cấu trúc mảng cứng nhắc, việc biểu diễn hành vi thành các đỉnh (*nodes*) và luồng di chuyển thành các cạnh (*edges*) mang lại khả năng mở rộng gần như không giới hạn. Trong tương lai, khi doanh nghiệp tung ra các tính năng mới trên ứng dụng (tương ứng với các mã hành động mới), mạng nơ-ron đồ thị có thể dễ dàng tiếp nhận, tự động mở rộng ma trận kề và lập bản đồ các hành vi này một cách tự nhiên mà không đòi hỏi kỹ sư phải thiết kế lại toàn bộ kiến trúc lõi.

Đánh giá trên khẳng định rằng hệ sinh thái **ChronoLens** không chỉ xuất sắc tối ưu hóa thước đo khắt khe *Weighted MSE*, mà còn hoàn toàn đáp ứng các tiêu chuẩn công nghiệp về hiệu năng phần cứng, mang tính kế thừa cao và sẵn sàng thương mại hóa (*Production-ready*) ở quy mô doanh nghiệp.

VI. HỆ THỐNG ĐIỀU HÀNH CHRONO WEB

Nhằm hiện thực hóa giá trị của mô hình AI vào môi trường doanh nghiệp, chúng tôi đã đóng gói toàn bộ luồng suy luận của ChronoLens thành nền tảng Web tương tác thời gian thực (*real-time dashboard*). Hệ thống không chỉ đóng vai trò là một giao diện dự báo mà còn là trung tâm chỉ huy điều phối chuỗi cung ứng với 4 phân hệ cốt lõi **(Hình 4)**:

- **Tổng quan luồng dữ liệu:** Trực quan hóa bức tranh toàn cảnh về lưu lượng tương tác của khách hàng theo thời gian thực. Bảng điều khiển cung cấp các biểu đồ giám sát về phân phối độ dài chuỗi hành vi và các mã hành động vĩ mô đang chiếm ưu thế.
- **Dự báo tham số trực tiếp:** Cho phép người điều hành nhập trực tiếp một chuỗi hành vi bất kỳ (hoặc kết nối qua API) để hệ thống chạy luồng suy luận tiệm cận không độ trễ. Giao diện sẽ lập tức trả về 6 biến mục tiêu, bao gồm ngày/tháng bắt đầu, ngày/tháng kết thúc và 2 hệ số công suất tương ứng.
- **Tối ưu lịch trình và phân bổ đơn hàng:** Dựa trên khoảng thời gian dự báo (từ `attr_1`, `attr_2` đến

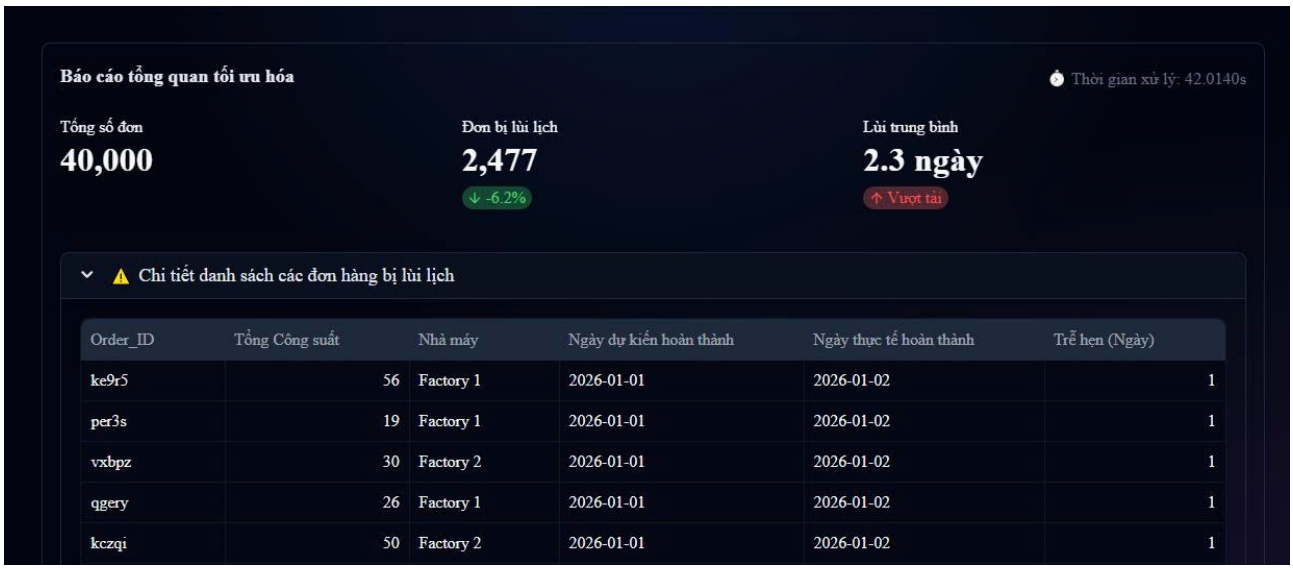

Order_ID	Tổng Công suất	Nhà máy	Ngày dự kiến hoàn thành	Ngày thực tế hoàn thành	Trễ hẹn (Ngày)
ke9r5	56	Factory 1	2026-01-01	2026-01-02	1
per3s	19	Factory 1	2026-01-01	2026-01-02	1
vxbpz	30	Factory 2	2026-01-01	2026-01-02	1
qgery	26	Factory 1	2026-01-01	2026-01-02	1
kczqi	50	Factory 2	2026-01-01	2026-01-02	1

Hình 4: Tính năng tối ưu lịch trình và phân bổ đơn hàng

`attr_4`, `attr_5`), hệ thống tự động băm nhỏ tổng khối lượng công việc để tính toán KPIs chia việc cho từng ngày. Thuật toán phân bổ giúp làm phẳng biểu đồ tải trọng, tránh tình trạng nhà máy rảnh rỗi đầu tháng nhưng lại dồn ứ cục bộ vào cuối tháng.

- **Cảnh báo rủi ro:** Tích hợp các ngưỡng an toàn (*thresholds*) cho 2 biến công suất (`attr_3`, `attr_6`). Nếu mô hình phát hiện một luồng hành vi có rủi ro đẩy công suất vượt mức 90% hoặc nguy cơ chậm tiến độ hoàn thành, hệ thống sẽ nhấp nháy tín hiệu báo động đỏ, tự động đề xuất phương án điều hướng tải sang các dây chuyền dự phòng.

VII. KẾT LUẬN

Bài báo cáo này trình bày **ChronoLens**, một framework lai thiết kế chuyên biệt để giải quyết bài toán hồi quy dự báo tham số vận hành có độ dài biến thiên. Bằng việc kết hợp quy trình huấn luyện hai giai đoạn (chưng cất đặc trưng), hàm mất mát tùy chỉnh *Asymmetric Hybrid-Threshold Loss*, và hệ sinh thái **Chrono Networks**, hệ thống đã khắc phục triệt để hiện tượng hội tụ lệch pha và tối ưu hóa xuất sắc thước đo Weighted MSE.

Từ sự thấu hiểu sâu sắc về dữ liệu, chúng tôi cụ thể hóa giá trị của mô hình thành ba trụ cột hành động đề xuất cho doanh nghiệp:

- **Tối ưu hóa công suất chủ động:** Dựa trên khả năng dự báo chính xác 6 tham số vận hành, hệ thống cung cấp căn cứ để phân bổ nguồn lực sản xuất và tối ưu diện tích kho bãi sát với điểm rơi nhu cầu, triệt tiêu sự lãng phí do điều phối bị động.
- **Cảnh báo đứt gãy chuỗi cung ứng:** Nhận diện sớm các chuỗi hành vi mang rủi ro tải trọng cao, giúp ban quản lý kích hoạt các kịch bản phòng ngừa trước khi hiện tượng quá tải thực sự xảy ra tại nhà máy.
- **Chiến lược điều hướng linh hoạt:** Tận dụng các "nút thắt" điều hướng trọng yếu đã được bóc tách qua Đồ thị nhân quả (như mã `102`), doanh nghiệp có thể thiết kế lại giao diện tương tác nhằm dàn đều lưu lượng, tránh các nút thắt cổ chai cục bộ trên hệ thống.

Kết quả thực nghiệm đã khẳng định sự vượt trội toàn diện của ChronoLens, đưa đội thi vươn lên vị trí Top 2 toàn bảng xếp hạng, đồng thời minh chứng tính minh bạch của mô hình qua khả năng giải thích (xAI). Để đưa ChronoLens vào môi trường thương mại hóa ở quy mô lớn, chúng tôi đề xuất lộ trình phát triển 3 giai đoạn:

- **Giai đoạn 1 - Triển khai luồng suy luận:** Đưa hệ thống XGBoost siêu nhẹ từ môi trường tĩnh lên nền tảng xử lý luồng Apache Kafka. Đồng thời, kết hợp song song cơ chế *Rule-based fallback* để tính toán nhanh các hằng số mặc định đối với nhóm khách hàng lướt nhanh ($\leq$ 3 bước) chưa đủ dữ kiện để đưa vào mô hình học sâu.
- **Giai đoạn 2 - Vận hành MLOps liên tục:** Thiết lập cơ chế học liên tục (*Continuous Learning*). Thay vì huấn luyện lại toàn bộ mạng nơ-ron gây tốn kém, hệ thống sẽ thu thập dữ liệu mới hàng tuần để tự động cập nhật lại các trọng số của lớp cây quyết định (Giai đoạn 2), giúp mô hình thích ứng cực nhanh với các biến động mùa vụ.
- **Giai đoạn 3 - Mở rộng sinh thái IoT:** Nâng cấp hệ sinh thái đồ thị Chrono-G để kết nối thêm các chiều dữ liệu mới (như dữ liệu cảm biến máy móc IoT, hồ sơ nhân khẩu học), biến ChronoLens từ một công cụ dự báo đơn lẻ thành bộ não điều phối toàn diện cho chuỗi cung ứng kỹ thuật số.

TÀI LIỆU THAM KHẢO

[1] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: synthetic minority over-sampling technique," *Journal of artificial intelligence research*, vol. 16, pp. 321–357, 2002.

[2] M. Buda, A. Maki, and M. A. Mazurowski, "A systematic study of the class imbalance problem in convolutional neural networks," *Neural networks*, vol. 106, pp. 249–259, 2018.

[3] T. DeVries and G. W. Taylor, "Improved regularization of convolutional neural networks with cutout," *arXiv preprint arXiv:1708.04552*, 2017.

[4] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. of the 2019 Conf. of the North American Chapter of the ACL: Human Language Technologies*, 2019, pp. 4171–4186.

[5] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: a simple way to prevent neural networks from overfitting," *The journal of machine learning research*, vol. 15, no. 1, pp. 1929–1958, 2014.

[6] P. J. Huber, "Robust estimation of a location parameter," in *Breakthroughs in statistics*. Springer, 1992, pp. 492–518.

[7] A. Kendall, Y. Gal, and R. Cipolla, "Multi-task learning using uncertainty to weigh losses for scene geometry and semantics," in *Proc. of the IEEE conf. on computer vision and pattern recognition*, 2018, pp. 7482–7491.

[8] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proc. of the IEEE int. conf. on computer vision*, 2017, pp. 2980–2988.

[9] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *International Conference on Learning Representations (ICLR)*, 2017.

[10] K. Cho, B. Van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," in *Proc. of the 2014 Conf. on Empirical Methods in NLP (EMNLP)*, 2014, pp. 1724–1734.

[11] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[12] D. Luo, X. Wang, et al., "ModernTCN: A Modern Pure Convolutional Structure for Time Series Analysis," in *International Conference on Learning Representations (ICLR)*, 2024.

[13] P. Dollár, P. Welinder, and P. Perona, "Fast feature pyramids for object detection," *IEEE transactions on pattern analysis and machine intelligence*, vol. 36, no. 8, pp. 1532–1545, 2014.

[14] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019.

[15] L. N. Smith and N. Topin, "Super-convergence: Very fast training of neural networks using large learning rates," in *Artificial intelligence and ML for multi-domain operations applications*, vol. 11006. SPIE, 2019, p. 1100612.

[16] L. Breiman, "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.

[17] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. of the 22nd acm sigkdd int. conf. on knowledge discovery and data mining*, 2016, pp. 785–794.

[18] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in neural information processing systems*, vol. 30, 2017.

[19] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," *arXiv preprint arXiv:1301.3781*, 2013.

[20] J. H. Friedman, "Greedy function approximation: a gradient boosting machine," *Annals of statistics*, pp. 1189–1232, 2001.

[21] C. Rudin, "Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead," *Nature Machine Intelligence*, vol. 1, no. 5, pp. 206–215, 2019.

[22] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of hallucination in natural language generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1–38, 2023.

PHỤ LỤC

A. *Phân tích kỹ thuật các hành vi chuỗi*

1) Ma trận xác suất chuyển đổi hành vi: Phân tích ma trận chuyển đổi (Hình 5) giúp khoanh vùng các luồng chảy chính và các nút thắt (*bottleneck*) trong ứng dụng. Khác với giả định về các quy trình thủ tục mang tính tuyến tính bắt buộc (xác suất 100%), dữ liệu thực tế bộc lộ tính phân nhánh rất cao của người dùng, với các chuyển đổi lớn nhất chỉ đạt mức xấp xỉ 33%.

Cụ thể, ma trận làm lộ diện mã `105` đóng vai trò là một "trạm trung chuyển" khổng lồ. Hàng loạt các hành động khác nhau đều có xu hướng hội tụ mạnh mẽ về `105`, tiêu biểu như từ `929` (33%), `8615` (32%), và `867` (31%). Tương tự, mã `102` cũng là một điểm đến vệ tinh thu hút lưu lượng đáng kể từ các mã trên (chiếm $10\% - 14\%$).

Ở một diễn biến độc lập khác, điểm `975` ghi nhận hành vi chuyển tiếp cục bộ rất mạnh sang `103` (31%). Đáng chú ý, các mã hành động vĩ mô ở cuối chuỗi như `20022`, `21040`, `21355` gần như phớt lờ mọi thao tác khác và có xu hướng chuyển tiếp độc quyền sang mã `975` ($10\% - 11\%$).

Những phát hiện định lượng này khẳng định sự tồn tại của các "giao lộ" hành vi. Việc hệ thống nhận diện và kiểm soát tốt các giao lộ như `105` hay `102` chính là "thời điểm vàng" để đưa ra quyết định điều phối lưu lượng, chủ động phân luồng tải trọng nhà máy nhằm tối ưu hóa chuỗi cung ứng.

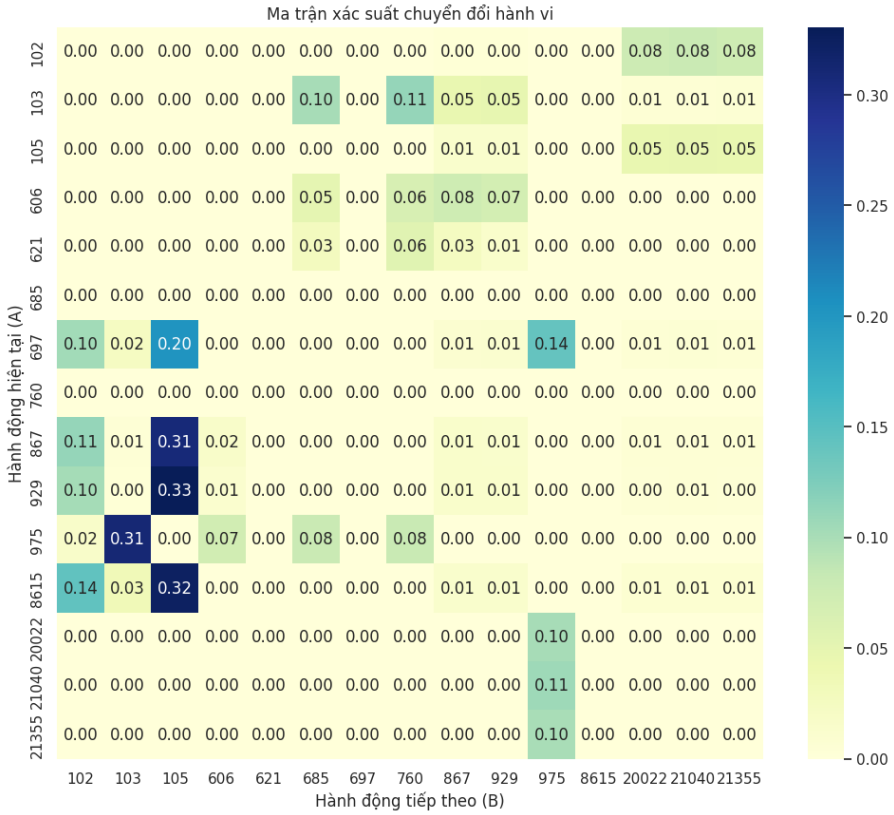

Hình 5: Ma trận xác suất chuyển đổi giữa các mã hành động phổ biến

2) Các cụm hành động phổ biến: Chúng tôi ghi nhận các luồng tương tác phổ biến nhất của người dùng thông qua phân tích Bigram và Trigram:

Bảng V: Top 10 cụm 2 hành động liên tiếp phổ biến nhất

STT	Cụm hành động (Pattern)	Tần suất (Lần)
1	(10477, 697)	7590
2	(760, 1593)	7539
3	(1593, 8615)	7531
4	(685, 2207)	7441
5	(2207, 8615)	7429
6	(760, 1165)	7397
7	(1076, 658)	6210
8	(685, 1464)	5741
9	(8615, 105)	4836
10	(102, 21040)	3701

Bảng VI: Top 10 cụm 3 hành động liên tiếp phổ biến nhất

STT	Cụm hành động (Pattern)	Tần suất (Lần)
1	(760, 1593, 8615)	7531
2	(685, 2207, 8615)	7429
3	(1593, 8615, 105)	2451
4	(2207, 8615, 105)	2385
5	(10477, 697, 105)	2343
6	(760, 1165, 105)	2254
7	(685, 1464, 105)	1859
8	(7362, 2621, 166)	1722
9	(164, 17762, 2613)	1718
10	(12516, 5451, 4521)	1711

- **Sự tồn tại của các luồng thủ tục cố định (*Deterministic Paths*):** Quan sát dữ liệu, ta thấy tần suất của cặp `(760, 1593)` là 7539 lần, trong khi chuỗi ba `(760, 1593, 8615)` đạt 7531 lần. Tương tự, cặp `(685, 2207)` đạt 7441 lần và chuỗi `(685, 2207, 8615)` đạt 7429 lần. Tỷ lệ bảo toàn lưu lượng gần như tuyệt đối (trên 99%) này chứng tỏ đây không phải là lựa chọn ngẫu nhiên của người dùng, mà là các luồng thủ tục khởi tạo mang tính hệ thống (ví dụ: *Mở app* $\rightarrow$ *Xác thực* $\rightarrow$ *Tải dữ liệu trang chủ*).
- **Cấu trúc "Phễu điều hướng" hội tụ về yết hầu `105`:** Bức tranh toàn cảnh về hành trình khách hàng trở nên cực kỳ mạch lạc khi ghép nối các Trigrams. Hai nhánh xuất phát điểm chính (bắt đầu bằng `760` và `685`) đều hội tụ tuyệt đối về mã `8615`. Ngay sau đó, `8615` tiếp tục đổ dồn lưu lượng về mã `105`, thể hiện qua các Trigram top 3 và 4: `(1593, 8615, 105)` và `(2207, 8615, 105)`. Tổng tần suất của 2 chuỗi này là 4836, khớp chính xác 100% với tần suất của Bigram `(8615, 105)`.
- **Hợp lưu toàn cục:** Không chỉ có nhánh `8615`, nhánh xuất phát phổ biến nhất `(10477, 697)` (Bigram Top 1) cũng trỏ thẳng về `105`, minh chứng qua Trigram Top 5 `(10477, 697, 105)`.

Những con số biết nói này khẳng định mã `105` chính là "yết hầu" (*bottleneck*) trung tâm của toàn bộ ứng dụng. Mọi luồng khách hàng từ các nhánh khởi tạo đều bị hút về phễu `105` trước khi họ thực hiện các tương tác tạo tải lên hệ thống nhà máy. Khả năng ghi nhớ và tự động trích xuất các quy luật N-grams nghiêm ngặt này chính là cơ sở để mạng nơ-ron định vị chính xác khoảng cách thời gian từ lúc khách hàng bắt đầu đến lúc hoàn thành giao dịch.

B. Đặc trưng thống kê và độ phức tạp của tham số

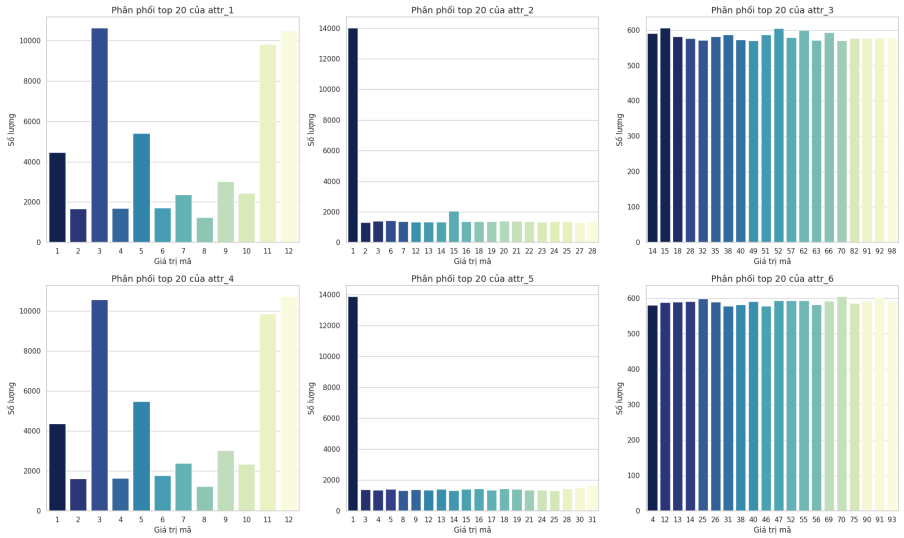

Hình 6: Thống kê mô tả và phân phối tần suất của 6 biến mục tiêu. Biểu đồ phản ánh rõ rệt các ràng buộc về lịch pháp, tính mùa vụ (nhóm Tháng), hiệu ứng chốt sổ đầu kỳ (nhóm Ngày) và cơ chế cân bằng tải đồng đều (nhóm Công suất).

1) Phân phối và giới hạn không gian của các thuộc tính: Như được thể hiện tại Hình 6, việc phân tích biểu đồ phân phối khẳng định rõ rệt bản chất của 6 biến mục tiêu, được chia thành 3 nhóm với các hành vi thống kê hoàn toàn khác biệt:

- **Nhóm Tháng (`attr_1`, `attr_4`):** Không gian giá trị giới hạn nghiêm ngặt từ 1 đến 12. Tuy nhiên, phân phối hoàn toàn không đồng đều mà tạo thành các đỉnh chóp (*spikes*) rất rõ rệt tại các tháng $1, 3, 5$ và giai đoạn cuối năm $(11, 12)$. Sự biến động này phản ánh tính mùa vụ (*seasonality*) cực cao trong hành vi tạo giao dịch, có khả năng tương đồng với các chu kỳ nhập/xuất hàng, chốt quý hoặc chiến dịch xả kho của doanh nghiệp.

- **Nhóm Ngày (`attr_2`, `attr_5`):** Phân phối trải dài từ 1 đến 31, nhưng ghi nhận một sự tập trung khổng lồ và áp đảo hoàn toàn vào mốc ngày 1 (đầu tháng) với xấp xỉ 14.000 lượt. Sự mất cân bằng (*extreme skewness*) này là dấu hiệu điển hình của các luồng công việc được thiết lập tự động (*batch processing*) hoặc thói quen lên đơn hàng loạt vào đầu kỳ kế toán. Mô hình cần đặc biệt cẩn trọng để không bị *bias* hoàn toàn vào mốc ngày 1.
- **Nhóm Công suất (`attr_3`, `attr_6`):** Biểu đồ biểu diễn top 20 giá trị phổ biến nhất (trải dài đến mốc tiệm cận 99) cho thấy một sự phân bổ phẳng và đồng đều một cách hoàn hảo (*uniform-like distribution*), với các cột dao động sát sao ở mức $550 - 600$ lượt. Sự cân bằng tuyệt đối này cho thấy hệ thống nhà máy đang duy trì một cơ chế điều phối tải trọng (*load balancing*) rất tốt. Đối với bài toán hồi quy, việc nhãn mục tiêu phân phối đều (*flat*) đòi hỏi mô hình phải có năng lực trích xuất các đặc trưng vi mô cực kỳ xuất sắc, thay vì chỉ dựa vào xác suất thống kê bề mặt.

2) Tương quan đa mục tiêu và Tính độc lập thống kê: Phân tích ma trận Cramer's V (Hình 7) giúp định lượng mối quan hệ phi tuyến giữa 6 biến mục tiêu, cung cấp nền tảng toán học để chúng tôi thiết kế kiến trúc luồng suy luận.

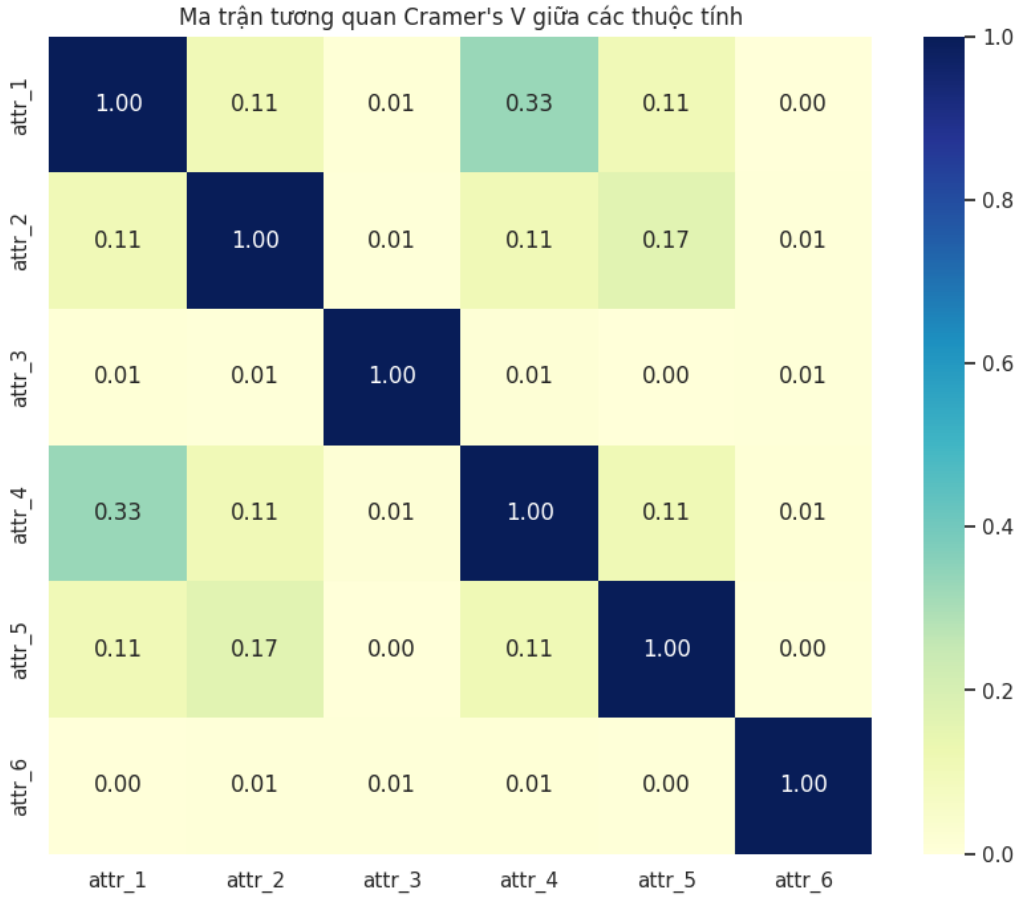

Hình 7: Ma trận tương quan Cramer's V thể hiện mối liên hệ giữa các thuộc tính đầu ra.

Dựa trên ma trận, chúng tôi bóc tách được hai đặc tính trái ngược hoàn toàn của tập dữ liệu:

- **Quán tính giao dịch của nhóm Thời gian:** Chỉ số tương quan giữa các cặp chéo thời gian vượt trội hơn hẳn phần còn lại, cụ thể: Tháng khởi tạo - Tháng hoàn thành (`attr_1` $\leftrightarrow$ `attr_4`) đạt 0.33, và Ngày khởi tạo - Ngày hoàn thành (`attr_2` $\leftrightarrow$ `attr_5`) đạt 0.17. Điều này minh chứng cho hiện tượng "quán tính giao dịch" (*transaction inertia*) - phần lớn các yêu cầu được hoàn thành rất nhanh trong cùng một chu kỳ thời gian ngắn kể từ lúc bắt đầu. Sự phụ thuộc tuyến tính này chính là bệ phóng để chúng tôi thiết kế cơ chế **Hồi quy phân tầng (Cascade Regression)**, ép mô hình phải lấy mốc thời gian bắt đầu làm "mỏ neo ngữ cảnh" trước khi dự đoán mốc hoàn thành.
- **Tính độc lập thống kê của nhóm Công suất:** Một phát hiện mang tính quyết định là sự cô lập hoàn toàn của hai biến công suất (`attr_3` và `attr_6`). Tương quan giữa chúng với nhau và với tất cả các biến thời gian khác đều xấp xỉ bằng không (0.00 đến 0.01). Trái với tư duy thông thường, khối lượng khởi tạo không hề định đoạt khối lượng hoàn thành. Tính chất biến thiên ngẫu nhiên và độc lập (*stochastic & independent*) này giải thích tại sao việc hồi quy công suất là thách thức lớn nhất của bài toán. Nó củng cố tính cấp thiết của việc áp đặt hệ số phạt khắt khe $\alpha = 100$ trong hàm *Asymmetric Hybrid-Threshold Loss* nhằm ép mạng nơ-ron đặc biệt chú ý đến hai biến dị biệt này thay vì bị cuốn theo các biến thời gian dễ đoán hơn.

C. Sự dịch chuyển phân phối đầu vào (Covariate Shift)

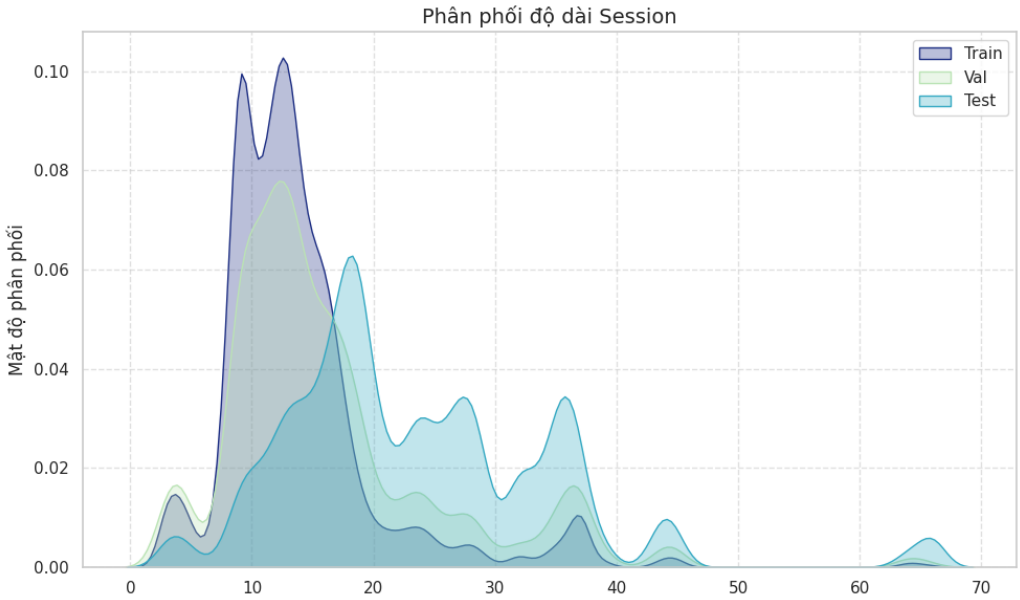

Hình 8: Biểu đồ KDE thể hiện mật độ phân phối độ dài chuỗi hành vi từ 3 tập: Train, Validation và Test.

Hình 8 phơi bày một hiện tượng dịch chuyển phân phối (*covariate shift*) cực kỳ nghiêm trọng về độ dài chuỗi đầu vào giữa tập huấn luyện và thực tế.

Dữ liệu bộc lộ hai thái cực hoàn toàn đối lập:

- **Tập Train và Validation (Chuỗi ngắn):** Mật độ phân phối tập trung dày đặc tạo thành hai đỉnh tháp nhọn ở mốc 9 và 13 hành động. Ngay sau mốc 15, đường mật độ lao dốc mạnh và gần như tiệm cận 0 ở các chuỗi dài (từ 20 trở lên).
- **Tập Public Test (Chuỗi dài và phức tạp):** Phân phối của tập kiểm thử bị *lệch phải* (*right-skewed*) một cách cực đoan. Khối lượng giao dịch chính không nằm ở mốc 9-13 mà dịch chuyển hẳn sang đỉnh $18 - 20$. Đáng báo động hơn, tập Test xuất hiện một dải đuôi rất dài (*long-tail*) với hàng loạt các đỉnh phụ cuồn cuộn ở các mốc $25, 28, 35, 40$ và thậm chí xuất hiện cụm giao dịch lên tới $65 - 70$ hành động.

Về mặt nghiệp vụ, sự xuất hiện ồ ạt của các chuỗi dài bất thường trên tập Test có thể đại diện cho các hành vi gom hàng sỉ (B2B), các yêu cầu tùy chỉnh cấu hình phức tạp, hoặc sự thay đổi trong luồng UI/UX của nền tảng tại thời điểm thu thập dữ liệu Test.

Về mặt kỹ thuật, hiện tượng này là "bản án tử" đối với các mô hình học sâu thông thường. Một mạng nơ-ron chỉ quen nhìn thấy chuỗi ngắn (tập Train) sẽ gặp hiện tượng suy giảm hiệu suất thảm hại khi bị ép phải trích xuất nhân quả trên luồng chuỗi dài dằng dặc (tập Test).

Phát hiện định lượng mang tính sống còn này là bệ phóng để chúng tôi thiết kế và áp dụng chiến lược **Nội suy động (*Dynamic Oversampling*)**. Thuật toán đã tự động phát hiện sự khan hiếm của các dải chuỗi dài (> 18 hành động) trong tập Train và tiến hành nhân bản chúng lên tối đa 10 lần. Việc "ép" mô hình tiếp xúc liên tục với các chuỗi dài hiếm hoi này giúp mạng nơ-ron học được khả năng ghi nhớ dài hạn, tạo ra sức đề kháng mạnh mẽ trước sự xô lệch phân phối, qua đó bảo toàn vững chắc điểm số WMSE trên bảng xếp hạng thực tế.

D. Trực quan hóa mạng lưới nhân quả

Nhằm cung cấp một góc nhìn đa chiều về "topo học" của luồng khách hàng từ mức độ vi mô (ít kết nối) đến vĩ mô (dày đặc kết nối), Phụ lục này trình bày chi tiết sự biến đổi của đồ thị khi thay đổi số lượng cạnh (*edges*) được giữ lại.

Hình 9 minh họa cấu trúc mạng lưới tương ứng với các ngưỡng 50, 100, 150 và 200 cạnh có trọng số Attention cao nhất. Toàn bộ các đồ thị trong phụ lục này đều được trích xuất trực tiếp từ các ma trận trọng số của mô hình **Chrono-G** sau khi đã hội tụ hoàn toàn.

E. Phân tích hành vi gây nhiễu trên đa thuộc tính

Chúng tôi tiến hành mổ xẻ hiện tượng hệ thống dồn sự chú ý vào các "cú lừa" (*Distractors*) khi có mức sai số dự báo cao. Phụ lục này cung cấp các biểu đồ đối chiếu mức độ tập trung Attention giữa nhóm dự đoán Sai số thấp (Đúng) và Sai số cao (Sai) cho các thuộc tính $2, 3, 4, 6$ (Hình 10). Các biểu đồ được trích xuất từ cơ chế Attention của mô hình **Chrono-G**.

Lưu ý: Phân tích này không bao gồm Thuộc tính 1 (Tháng bắt đầu) và Thuộc tính 5 (Tháng hoàn thành). Do dữ liệu phân phối cực kỳ tập trung và mô hình đạt khả năng hồi quy gần như hoàn hảo trên hai biến thời gian này, các sai số (nếu có) là vô cùng nhỏ. Do đó, mạng nơ-ron không bị chi phối rõ rệt bởi bất kỳ mã hành động gây nhiễu nào, khiến việc trực quan hóa không mang lại ý nghĩa thống kê.

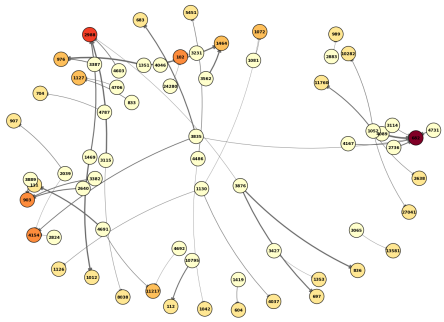

(a) Top 50 cạnh mạnh nhất

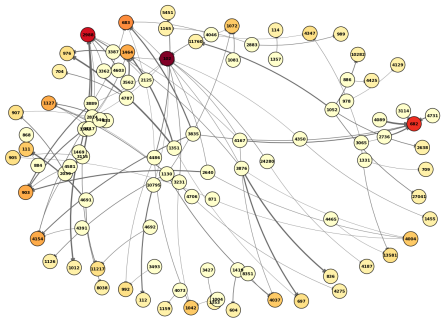

(b) Top 100 cạnh mạnh nhất

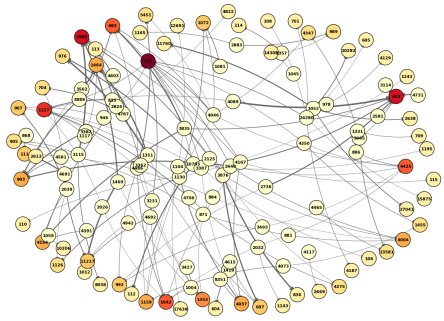

(c) Top 150 cạnh mạnh nhất

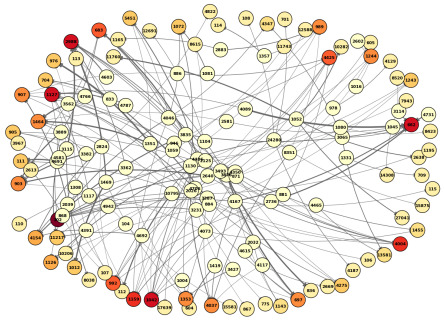

(d) Top 200 cạnh mạnh nhất

Hình 9: Sự tiến hóa của mạng lưới nhân quả khi tăng dần số lượng cạnh trọng yếu. Có thể thấy rõ các nút thắt (*bottlenecks*) như mã `102` luôn duy trì vai trò trung tâm cốt lõi, bất chấp việc đồ thị xuất hiện thêm nhiều luồng hành vi phụ trợ ở các ngưỡng cạnh lớn hơn.

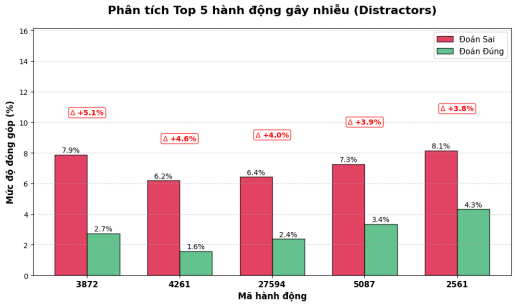

(a) Thuộc tính 2 (Ngày bắt đầu)

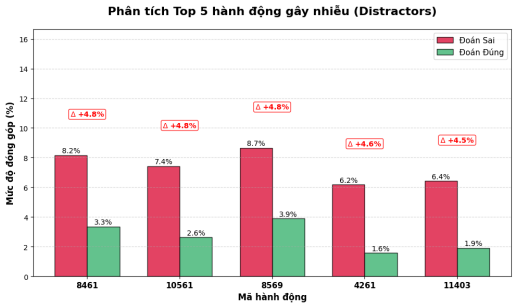

(b) Thuộc tính 3 (Công suất khởi tạo)

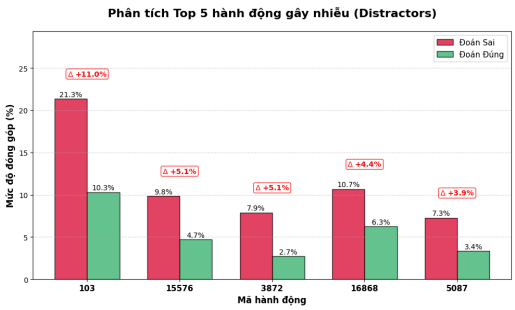

(c) Thuộc tính 4 (Tháng hoàn thành)

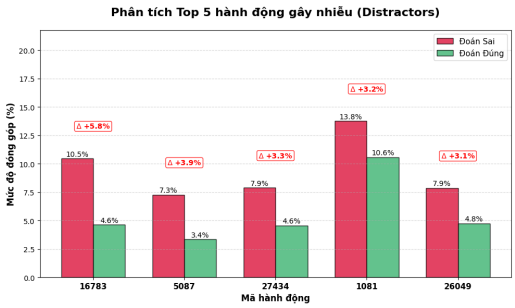

(d) Thuộc tính 6 (Công suất hoàn thành)

Hình 10: Biểu đồ đối chiếu Attention vào các hành động gây nhiễu giữa dự đoán có Sai số cao (Sai) và Sai số thấp (Đúng) trên 4 thuộc tính. Thuộc tính 1 và 5 không được biểu diễn do mô hình kháng nhiễu cực tốt, không bị tác động bởi các distractors.